ClaimAI — техническое приложение

Методика, данные и исходники, метрики и тест-кейсы, план доработки (TRL)

1. Назначение и границы

ClaimAI — прототип системы поддержки решений для операторов споров по банковским картам. Система не принимает решение о выплате самостоятельно: она готовит рекомендацию с обоснованием, а оператор подтверждает её. Прототип работает на синтетических данных.

2. Методика и модель

- **Модель:** большая языковая модель через OpenAI API (по умолчанию gpt-4o-mini, модель и адрес API задаются переменными окружения OPENAI_MODEL и OPENAI_API_URL).
- **Вход:** номер кейса, текст жалобы и транзакции (мерчант, сумма, дата, способ аутентификации, канал).
- **Промпт:** системная инструкция задаёт роль движка, перечень учитываемых факторов (правила платёжных сетей, политика банка, 3-D Secure, канал, время, дубликаты, серии операций) и требует ответ единым JSON-объектом.
- **Режим генерации:** temperature 0,2 для воспроизводимости, JSON-режим (response_format = json_object), ограничение 1200 токенов.
- **Выход:** тип спора, решение, класс решения (green — автоматическое, orange — расследование, red — отказ), риск 0–100, уверенность 0–100, обоснование, список действий, письмо клиенту.
- **Контроль качества ответа:** из текста ответа извлекается JSON, проверяется наличие обязательных полей, числовые значения приводятся к диапазону 0–100, неизвестный класс решения заменяется на orange. При сбое API возвращается ошибка 502, подставных ответов нет.

3. Архитектура и исходники

Компонент	Реализация
Интерфейс	React 18 + Vite, страница с выбором кейса и анимацией этапов анализа
API	FastAPI: GET /api/health, GET /api/cases, GET /api/cases/{id}, POST /api/cases/{id}/analyze, GET /api/audit
Движок решений	backend/app/llm.py: формирование запроса, вызов LLM, разбор и нормализация ответа
База данных	SQLAlchemy 2.0; PostgreSQL в Docker и на Render, SQLite для локального запуска; таблицы кейсов, транзакций и журнала аудита
Развёртывание	Docker Compose; интерфейс на Vercel, API и база на Render (render.yaml)

Репозиторий: https://github.com/AliDamn/hack

Секреты: ключ API хранится только в переменных окружения и не попадает в репозиторий.

4. Данные

В прототипе используются четыре синтетических кейса, составленные по типовым сценариям споров. Реальные данные клиентов банков и номера карт не применяются. Для оценки качества необходим размеченный набор кейсов от банка-партнёра.

5. Тест-кейсы и метрики

Эталонные решения ниже зафиксированы разработчиком для демонстрационных кейсов и служат точкой отсчёта при сравнении ответов модели. Результаты прогона модели по эталону будут добавлены после запуска оценки с рабочим ключом API.

Кейс	Ситуация	Эталонный класс	Эталонное решение
DSP-0847	Списание 147 500 ₸ в онлайн-магазине без 3-D Secure; клиент не совершал покупку	green	Автоматический возврат, блокировка карты, fraud report
DSP-0846	Банкомат не выдал 200 000 ₸, деньги списаны	orange	Расследование: запрос в банк-владелец банкомата, видеозапись
DSP-0844	Два одинаковых списания по 7 800 ₸ с разницей 3 минуты	green	Автовозврат дубликата
DSP-0841	Пять ночных операций в Steam на 82 000 ₸ без 3-D Secure	green	Немедленный возврат, блокировка, передача в антифрод

Метрика	Способ измерения	Целевое значение (гипотеза)
Точность типа спора	Совпадение с разметкой эксперта	не менее 90%
Совпадение решения	Сравнение с решением оператора	не менее 85%
Время на спор	От жалобы до готового решения	минуты вместо часов
Доля автоматических решений	Зелёные решения без правки оператора	определить в пилоте
Ошибочные возвраты	Возврат при отсутствии оснований	минимум, контроль оператором

Целевые значения — рабочие гипотезы, а не измеренные результаты.

6. Ограничения прототипа

- Правила платёжных сетей пока передаются модели в виде общей инструкции, а не извлекаются из базы знаний.
- Жалоба и транзакции отправляются во внешний API: для продуктивного использования нужны маскирование персональных данных или локальная модель.
- Качество не измерено на размеченном наборе, решение требует подтверждения оператором.

7. План доработки и уровень готовности (TRL)

Срок	Уровень	Содержание
Сейчас	TRL 4	Рабочий прототип, 4 демо-кейса, журнал аудита, облачное развёртывание
1–2 мес.	TRL 4–5	База знаний с правилами Visa и Mastercard (RAG), ссылки на пункты правил в обосновании
2–4 мес.	TRL 5	Оценка на размеченном наборе, маскирование персональных данных, тесты
4–8 мес.	TRL 6	Пилот в банке или процессинге, сбор метрик и обратной связи операторов
8+ мес.	TRL 7	Интеграция с карточным процессингом, локальная модель внутри периметра банка

8. Источники рыночных данных

- Mastercard, State of Chargebacks 2025 (цифры по пересказу Chargebacks Gurus): объём и сумма споров, структура споров, стоимость обработки.
- Национальный банк Республики Казахстан: данные о мошенничестве за 2025 г. – март 2026 г. (по публикациям СМИ).
- Finprom: ущерб от мошенничества в Казахстане за 2022 г. (по публикациям СМИ).